




NATURAL LANGUAGE PROCESSING


3^η ΕΡΓΑΣΙΑ

ΤΡΙΜΠΟΥ ΕΛΕΥΘΕΡΙΑ

ΕΠΙΒΛΕΠΩΝ: ΡΕΦΑΝΙΔΗΣ ΙΩΑΝΝΗΣ

ΘΕΣΣΑΛΟΝΙΚΗ 2024-2025

Περιεχόμενα



.....	1
1. Εισαγωγή.....	4
2.1 Δημιουργία και Περιγραφή του Επεξεργασμένου Συνόλου Δεδομένων BioASQ 2016b (Preprocessed_BioASQ_2016b_TrainValTest).....	5
2.2 Η Φύση του Προβλήματος: Πολυετικετική Ταξινόμηση με Όρους MeSH	6
2.3 Εξερευνητική Ανάλυση Δεδομένων (EDA) του Επεξεργασμένου Συνόλου Δεδομένων.....	7
3. Τεχνικές Προκλήσεις και Περιορισμοί (στο notebook biosaqtrimproueleftheria.ipynb)	10
4. Μεθοδολογία και Υλοποίηση	11
4.1 Επισκόπηση Ροής Εργασιών και Βασικές Βιβλιοθήκες.....	11
4.2 Ρύθμιση Περιβάλλοντος και Διαχείριση Ρυθμίσεων.....	11
4.3 Στρατηγική Top-K Filtering Ετικετών (Cell 4b)	11
4.4 Προετοιμασία Δεδομένων	12
4.5 Αρχιτεκτονική Μοντέλου (MeSHClassifier στο Cell 6a)	12
4.6 Διαδικασία Εκπαίδευσης.....	13
4.6.1 Οπτικοποίηση της Πορείας Εκπαίδευσης (Σχήμα 4)	14
4.7 Διαδικασία Αξιολόγησης (Memory-Safe) (Cell 8)	15
5. Πειραματικά Αποτελέσματα και Ανάλυση.....	16
5.1 Βελτιστοποίηση Κατωφλίου Απόφασης (Cell 9).....	16
5.1.1 Οπτική Επισκόπηση Αποτελεσμάτων Προχωρημένης Ανάλυσης (Σχήμα 6)	17
5.2 Συνολική Απόδοση με Βέλτιστο Κατώφλι (Cell 9 και Cell 10)	19
5.3 Υπολογιστικά Οφέλη.....	20
5.4 Ανάλυση Απόδοσης ανά Ετικέτα (Per-Label Analysis) (Cell 9)	20

5.5 Άλλες Οπτικοποιήσεις (Cell 7, Cell 10)	21
6. Συζήτηση και Ανάλυση Σφαλμάτων.....	22
6.1 Ερμηνεία Αποτελεσμάτων και Trade-offs	22
6.3 Περιορισμοί της Μελέτης.....	22
7. Συμπεράσματα.....	24

1. Εισαγωγή

Η παρούσα αναφορά παρουσιάζει μια ολοκληρωμένη προσέγγιση για την αυτόματη πολυετικετική ταξινόμηση ιατρικών επιστημονικών άρθρων σε προκαθορισμένους όρους MeSH (Medical Subject Headings). Η ταξινόμηση βασίστηκε αποκλειστικά στο κειμενικό περιεχόμενο του τίτλου και της περίληψης κάθε άρθρου, αξιοποιώντας το σύνολο δεδομένων BioASQ 2016b, το οποίο αντλείται από την εκτενή βιβλιογραφική βάση δεδομένων PubMed.

Η αυτόματη και ακριβής ανάθεση όρων MeSH σε επιστημονικές δημοσιεύσεις είναι θεμελιώδους σημασίας για την αποτελεσματική οργάνωση της βιοϊατρικής βιβλιογραφίας, επιτρέποντας την ταχεία αναζήτηση και αξιόπιστη ανάκτηση πληροφοριών. Η υπολογιστική επίλυση αυτού του προβλήματος, ωστόσο, ενέχει σημαντικές τεχνικές προκλήσεις. Κυρίαρχη είναι η εξαιρετικά υψηλή διαστατικότητα του χώρου των ετικετών, καθώς το αρχικό σύνολο δεδομένων εκπαίδευσης περιλάμβανε 23.495 μοναδικούς όρους MeSH. Αυτός ο μεγάλος αριθμός πιθανών ετικετών ανά άρθρο κατατάσσει το πρόβλημα στην κατηγορία της ακραίας πολυετικετικής ταξινόμησης, επιβάλλοντας σημαντικές υπολογιστικές απαιτήσεις. Η πολυπλοκότητα επιτείνεται από την έντονη αραιότητα (sparsity) και την ανισοβαρία (skewness) στην κατανομή των ετικετών: ένα μικρό υποσύνολο όρων εμφανίζεται με υψηλή συχνότητα, ενώ η συντριπτική πλειοψηφία χαρακτηρίζεται από ελάχιστες εμφανίσεις. Αυτό το φαινόμενο, γνωστό ως "long-tail distribution", περιορίζει τον αριθμό των διαθέσιμων παραδειγμάτων για την εκμάθηση των προτύπων που αντιστοιχούν στις περισσότερες ετικέτες, δυσχεραίνοντας την επίτευξη υψηλής συνολικής απόδοσης, ιδιαίτερα σε μετρικές που αποδίδουν ίση βαρύτητα σε όλες τις κατηγορίες ετικετών.

Οι προαναφερθείσες προκλήσεις της υψηλής διαστατικότητας και της αραιότητας των ετικετών επιδεινώθηκαν περαιτέρω από τους αυστηρούς περιορισμούς υπολογιστικών πόρων που χαρακτήριζαν το περιβάλλον ανάπτυξης. Συγκεκριμένα, η εργασία υλοποιήθηκε στην πλατφόρμα Kaggle, η οποία επιβάλλει συγκεκριμένα όρια, όπως το χρονικό περιθώριο εκτέλεσης των notebooks, η περιορισμένη διαθέσιμη μνήμη GPU, καθώς και οι περιορισμοί στην κύρια μνήμη RAM. Υπό αυτές τις συνθήκες, η διαχείριση ενός προβλήματος με 23.495 πιθανές εξόδους κατέστη εξαιρετικά δύσκολη. Πράγματι, οι αρχικές, διερευνητικές απόπειρες για την εκπαίδευση ενός μοντέλου BioBERT με το πλήρες σύνολο των ετικετών προσέκρουσαν άμεσα σε αυτά τα εμπόδια: η διαδικασία οδηγούσε συστηματικά σε σφάλματα εξάντλησης μνήμης (Out-Of-Memory, OOM), ιδιαίτερα κατά τον υπολογισμό των βαθμίδων (backward pass), ενώ οι εκτιμώμενοι χρόνοι εκπαίδευσης για μία μόνο εποχή υπερέβαιναν κατά πολύ τα επιτρεπτά όρια, καθιστώντας την προσέγγιση αυτή μη πρακτική. Κατά συνέπεια, κατέστη επιτακτική η ανάγκη για την υιοθέτηση μιας στρατηγικής που θα μείωνε δραστικά την πολυπλοκότητα του προβλήματος, επιτρέποντας την εκπαίδευση εντός των δεδομένων περιορισμών, χωρίς όμως να θυσιάζεται ολοκληρωτικά η ικανότητα του μοντέλου να παράγει χρήσιμες προβλέψεις.

Ως εκ τούτου, η κεντρική στρατηγική που υιοθετήθηκε ήταν η Top-K Filtering των ετικετών. Η προσέγγιση αυτή επικεντρώθηκε στην επιλογή ενός υποσυνόλου των πιο συχνά εμφανιζόμενων ετικετών (συγκεκριμένα, των 2.000 πιο συχνών), με στόχο τη δημιουργία ενός πιο αποδοτικού, ελαφρού, αλλά και πρακτικά αποτελεσματικού συστήματος ταξινόμησης. Η παρούσα αναφορά θα αναλύσει διεξοδικά τις τεχνικές

προκλήσεις, την υιοθετηθείσα μεθοδολογία και υλοποίηση, τα πειραματικά αποτελέσματα που προέκυψαν, καθώς και τα τελικά συμπεράσματα.

2.1 Δημιουργία και Περιγραφή του Επεξεργασμένου Συνόλου Δεδομένων BioASQ 2016b (Preprocessed_BioASQ_2016b_TrainValTest)

Η βάση για την παρούσα εργασία αποτέλεσε το σύνολο δεδομένων της πρόκλησης BioASQ, συγκεκριμένα το Task 1b του έτους 2016, το οποίο επικεντρώνεται στη μεγάλης κλίμακας σημασιολογική ευρετηρίαση βιοϊατρικών άρθρων. Τα δεδομένα, προερχόμενα από τη βάση PubMed, λήφθηκαν από την επίσημη ιστοσελίδα του BioASQ υπό τη μορφή ενός ενιαίου αρχείου JSON (allMeSH_limitjournals_2016.json, όπως ορίστηκε στο INPUT_JSON_PATH του κώδικα προετοιμασίας). Αυτό το αρχείο περιείχε μια μεγάλη συλλογή άρθρων, όπου κάθε άρθρο περιλάμβανε κρίσιμα πεδία όπως pmid (μοναδικό αναγνωριστικό), title, abstractText, και meshMajor (η λίστα των όρων MeSH).

Δεδομένου του μεγάλου όγκου του αρχικού αρχείου και της ανάγκης για δομημένα υποσύνολα εκπαίδευσης, επικύρωσης και δοκιμής, πραγματοποιήθηκε μια διαδικασία προεπεξεργασίας και διαχωρισμού για τη δημιουργία του τελικού dataset (Preprocessed_BioASQ_2016b_TrainValTest) που χρησιμοποιήθηκε στην πλατφόρμα Kaggle. Αυτή η διαδικασία, όπως υλοποιήθηκε στον παρεχόμενο κώδικα (Cells 0-5 του notebook προετοιμασίας), περιλάμβανε τα ακόλουθα βασικά βήματα:

1. Καταμέτρηση Συνολικών Άρθρων (Cell 2): Αρχικά, έγινε μια πλήρης σάρωση του αρχείου εισόδου JSON χρησιμοποιώντας τη βιβλιοθήκη `ijson` (η οποία επιτρέπει την επεξεργασία μεγάλων αρχείων JSON τμηματικά, χωρίς να φορτώνονται ολόκληρα στη μνήμη). Αυτό το βήμα ήταν απαραίτητο για να προσδιοριστεί ο συνολικός αριθμός των διαθέσιμων άρθρων (`total_articles_in_file`) και να γίνει έλεγχος αν επαρκούν για τα επιθυμητά μεγέθη των υποσυνόλων. Σε περίπτωση που τα διαθέσιμα άρθρα ήταν λιγότερα από τα ζητούμενα, τα μεγέθη των υποσυνόλων προσαρμόστηκαν αναλογικά.
2. Δημιουργία και Ανάμειξη Τυχαίων Δεικτών (Cell 3): Για να εξασφαλιστεί η τυχαιότητα και η αμεροληψία στον διαχωρισμό των δεδομένων, δημιουργήθηκε ένας πίνακας με όλους τους δυνατούς δείκτες των άρθρων (από 0 έως `total_articles_in_file - 1`). Αυτός ο πίνακας αναμείχθηκε χρησιμοποιώντας τη συνάρτηση `np.random.shuffle` (με καθορισμένο `RANDOM_SEED = 42` για αναπαραγωγιμότητα). Από αυτόν τον αναμεμιγμένο πίνακα, επιλέχθηκαν οι πρώτοι `TOTAL_SAMPLES_TO_EXTRACT` ($140.000 + 30.000 + 30.000 = 200.000$) δείκτες.
3. Διαχωρισμός Δεικτών σε Υποσύνολα (Cell 3): Οι επιλεγμένοι 200.000 αναμεμιγμένοι δείκτες κατανεμήθηκαν στα τρία επιθυμητά υποσύνολα:
 - Οι πρώτοι `NUM_TRAIN_SAMPLES` (140.000) δείκτες για το σύνολο εκπαίδευσης (`train_indices_set`).

- Οι επόμενοι NUM_VAL_SAMPLES (30.000) δείκτες για το σύνολο επικύρωσης (val_indices_set).
 - Οι υπόλοιποι NUM_TEST_SAMPLES (30.000) δείκτες για το σύνολο δοκιμής (test_indices_set).
Έγινε έλεγχος για να διασφαλιστεί ότι δεν υπήρχε αλληλοεπικάλυψη δεικτών μεταξύ των υποσυνόλων.
4. Εξαγωγή και Εγγραφή Άρθρων σε Αρχεία JSON Lines (Cell 4): Το αρχικό αρχείο JSON διαβάστηκε ξανά τμηματικά. Για κάθε άρθρο, ελέγχθηκε αν ο τρέχων δείκτης του ανήκε σε κάποιο από τα προκαθορισμένα σύνολα δεικτών (train, val, ή test). Αν ναι, και εφόσον δεν είχε ήδη συλλεχθεί ο επιθυμητός αριθμός άρθρων για το συγκεκριμένο υποσύνολο, το άρθρο (με τα επιλεγμένα πεδία pmid, title, abstractText, meshMajor, year, journal) προστίθετο στην αντίστοιχη λίστα (π.χ., train_articles_list).
- Μετά τη συλλογή όλων των απαραίτητων άρθρων, κάθε μία από τις τρεις λίστες (train, val, test) γράφτηκε σε ένα ξεχωριστό αρχείο μορφής JSON Lines (.jsonl), με κάθε άρθρο να καταλαμβάνει μία γραμμή. Συγκεκριμένα, δημιουργήθηκαν τα αρχεία:
- train_140k.jsonl (140.000 άρθρα)
 - val_30k.jsonl (30.000 άρθρα)
 - test_30k.jsonl (30.000 άρθρα)
- Αυτά τα τρία αρχεία αποτέλεσαν το τελικό dataset Preprocessed_BioASQ_2016b_TrainValTest που μεταφορτώθηκε και χρησιμοποιήθηκε στην πλατφόρμα Kaggle.
5. Τελικός Έλεγχος (Cell 5): Πραγματοποιήθηκε έλεγχος του αριθμού γραμμών στα παραγόμενα αρχεία .jsonl για να επιβεβαιωθεί η ορθότητα της διαδικασίας, καθώς και μια προεπισκόπηση μερικών γραμμών από το αρχείο εκπαίδευσης.

Αυτή η λεπτομερής διαδικασία προετοιμασίας εξασφάλισε τη δημιουργία ενός καλά δομημένου και αναπαραγώγιμου συνόλου δεδομένων, κατάλληλου για την εκπαίδευση και την αξιόπιστη αξιολόγηση των μοντέλων πολυετικετικής ταξινόμησης.

2.2 Η Φύση του Προβλήματος: Πολυετικετική Ταξινόμηση με Όρους MeSH


Το αντικείμενο της παρούσας εργασίας είναι η ανάπτυξη ενός συστήματος για την αυτόματη απόδοση όρων MeSH σε βιοϊατρικά επιστημονικά άρθρα. Οι όροι MeSH αποτελούν ένα εκτενές, ιεραρχικά δομημένο και ελεγχόμενο λεξιλόγιο, το οποίο χρησιμοποιείται διεθνώς, διευκολύνοντας την αναζήτηση και ανάκτηση πληροφοριών. Η ιεραρχική φύση των MeSH επιτρέπει την περιγραφή εννοιών σε διαφορετικά επίπεδα εξειδίκευσης.

Η συγκεκριμένη υπολογιστική πρόκληση εμπίπτει στην κατηγορία της πολυετικετικής ταξινόμησης (multi-label classification). Σε αντίθεση με προβλήματα όπου κάθε αντικείμενο αντιστοιχίζεται σε μία μοναδική κατηγορία (multi-class classification), στην

πολυετικετική προσέγγιση, κάθε ιατρικό άρθρο δύναται να συσχετιστεί ταυτόχρονα με ένα υποσύνολο πολλαπλών όρων MeSH. Επομένως, ο στόχος είναι η ανάπτυξη ενός μοντέλου ικανού να προβλέπει με ακρίβεια το κατάλληλο σύνολο όρων MeSH για κάθε άρθρο, βασιζόμενο αποκλειστικά στα κειμενικά δεδομένα του τίτλου και της περίληψής του.

2.3 Εξερευνητική Ανάλυση Δεδομένων (EDA) του Επεξεργασμένου Συνόλου Δεδομένων

Αφού δημιουργήθηκε το τελικό σύνολο δεδομένων `Preprocessed_BioASQ_2016b_TrainValTest`, το επόμενο βήμα, το οποίο πραγματοποιήθηκε στο κύριο notebook της εργασίας με την ονομασία `biosaqtrimproueleftheria.ipynb`, ήταν η διεξαγωγή μιας αρχικής Εξερευνητικής Ανάλυσης Δεδομένων (EDA). Για τον σκοπό αυτό, και για λόγους αποδοτικότητας, χρησιμοποιήθηκε ένα δείγμα 10.000 άρθρων από το αρχείο εκπαίδευσης `train_140k.jsonl` (όπως υλοποιήθηκε στο Cell 4a του εν λόγω notebook `biosaqtrimproueleftheria.ipynb`). Στόχος αυτής της ανάλυσης ήταν η καλύτερη κατανόηση των χαρακτηριστικών των δεδομένων που θα τροφοδοτούσαν το μοντέλο.




Σχήμα 1: Κατανομή του αριθμού των Όρων MeSH ανά Άρθρο. Τα δεδομένα προέρχονται από ένα δείγμα 10.000 άρθρων του αρχείου `train_140k.jsonl` (αποτέλεσμα εκτέλεσης του Cell 4a του notebook `biosaqtrimproueleftheria.ipynb`).

Αριθμός Ετικετών ανά Άρθρο και Συνολική Κατανομή Συχνότητας Ετικετών:

Ένα κρίσιμο χαρακτηριστικό του συνόλου δεδομένων είναι ο αριθμός των ετικετών

MeSH που αντιστοιχούν σε κάθε άρθρο, καθώς και η συνολική συχνότητα εμφάνισης κάθε μοναδικής ετικέτας.

- Ανάλυση Σχήματος 1 (Κατανομή Όρων MeSH ανά Άρθρο): Το Σχήμα 1, το οποίο προέρχεται από την ανάλυση ενός δείγματος 10.000 άρθρων από το σύνολο εκπαίδευσης (εκτέλεση του Cell 4a στο notebook biosaqtrimproueleftheria.ipynb), απεικονίζει την κατανομή του πλήθους των όρων MeSH που έχουν ανατεθεί σε κάθε άρθρο. Παρατηρούμε ότι:
 - Η κατανομή προσεγγίζει μια κανονική κατανομή, αν και με ελαφρά δεξιά ασυμμετρία.
 - Η συντριπτική πλειοψηφία των άρθρων είναι πολυετικετική, δηλαδή φέρει πολλαπλούς όρους MeSH. Πολύ λίγα άρθρα έχουν λιγότερες από 3-4 ετικέτες.
 - Η κορύφωση της κατανομής, δηλαδή ο συχνότερος αριθμός ετικετών ανά άρθρο, εντοπίζεται γύρω στις 12-14 ετικέτες.
 - Ένας σημαντικός αριθμός άρθρων φέρει μεταξύ 5 και 20 ετικετών.
 - Ο αριθμός των άρθρων μειώνεται καθώς αυξάνεται ο αριθμός των ετικετών πέραν των 20-25, αν και υπάρχουν άρθρα με έως και 30-35 ετικέτες.Αυτή η παρατήρηση επιβεβαιώνει την πολυετικετική φύση του προβλήματος και υποδεικνύει ότι τα μοντέλα πρέπει να είναι ικανά να προβλέπουν ένα μεταβλητό, και συχνά σημαντικό, αριθμό ετικετών για κάθε είσοδο.
- Συχνότητα Εμφάνισης των Μοναδικών Ετικετών MeSH: Πέρα από το πόσες ετικέτες έχει κάθε άρθρο, η ανάλυση του πλήρους συνόλου εκπαίδευσης (140.000 άρθρα), όπως πραγματοποιήθηκε στο Cell 4b του notebook biosaqtrimproueleftheria.ipynb κατά την προετοιμασία για το Top-K filtering, αποκάλυψε την ύπαρξη 23.495 μοναδικών ετικετών MeSH συνολικά. Η ανάλυση αυτή έδειξε περαιτέρω ότι η συχνότητα εμφάνισης αυτών των μοναδικών ετικετών ήταν εξαιρετικά ανισοβαρής: η πιο συχνή ετικέτα εμφανιζόταν σε δεκάδες χιλιάδες άρθρα, ενώ ένας τεράστιος αριθμός ετικετών (η "μακριά ουρά" της κατανομής) εμφανιζόταν ελάχιστες φορές, ακόμη και μία μόνο φορά σε ολόκληρο το σύνολο εκπαίδευσης. Αυτή η ακραία ανισοκατανομή και η αραιότητα των περισσότερων ετικετών αποτέλεσαν την κύρια κινητήρια δύναμη πίσω από την απόφαση για εφαρμογή της στρατηγικής Top-K filtering.



Σχήμα 2: Κατανομή του Μήκους Περίληψης σε χαρακτήρες. Τα δεδομένα προέρχονται από το ίδιο δείγμα 10.000 άρθρων του αρχείου `train_140k.jsonl` (αποτέλεσμα εκτέλεσης του Cell 4a του notebook `biosaqtrimproueleftheria.ipynb`). Η γραμμή δείχνει μια εκτίμηση της πυκνότητας της κατανομής (KDE).

Μήκος Περιλήψεων και οι Επιπτώσεις του:

Το Σχήμα 2 (προερχόμενο από το Cell 4a του notebook `biosaqtrimproueleftheria.ipynb`) απεικονίζει την κατανομή του μήκους των περιλήψεων των άρθρων, μετρούμενο σε συνολικό αριθμό χαρακτήρων, για το δείγμα των 10.000 άρθρων εκπαίδευσης.

- Παρατηρήσεις από το Γράφημα: Το ιστόγραμμα δείχνει μια κατανομή με σαφή δεξιά ασυμμετρία (right-skewed), με την πλειοψηφία των περιλήψεων να έχει μήκος που συγκεντρώνεται στην περιοχή μεταξύ περίπου 500 και 2500 χαρακτήρων. Η κορύφωση της κατανομής (η συχνότερη τιμή) φαίνεται να βρίσκεται γύρω στους 1500-1800 χαρακτήρες. Υπάρχει μια "ουρά" προς τα δεξιά που υποδηλώνει την ύπαρξη ορισμένων, αν και λιγότερων, άρθρων με πολύ εκτενείς περιλήψεις (έως και πάνω από 8000 χαρακτήρες σύμφωνα με τα στατιστικά). Η καμπύλη εκτίμησης πυκνότητας (KDE) που έχει υπερτεθεί επιβεβαιώνει αυτή τη μορφή της κατανομής.
- Στατιστικά Στοιχεία: Τα στατιστικά που εξήχθησαν από τον κώδικα (Min=54, Mean=1444, Median=1474, Max=9256, 95th Perc=2219) παρέχουν περαιτέρω πληροφορίες. Ο μέσος όρος (1444) και η διάμεσος (1474) είναι σχετικά κοντά, αλλά η ύπαρξη μιας μέγιστης τιμής 9256 χαρακτήρων επιβεβαιώνει την παρουσία ακραίων τιμών. Το 95ο εκατοστημόριο στους 2219 χαρακτήρες υποδηλώνει ότι το 95% των περιλήψεων έχει μήκος μικρότερο ή ίσο με αυτή την τιμή.
- Συνέπειες για τη Μοντελοποίηση: Αυτή η ανάλυση του μήκους των περιλήψεων είναι κρίσιμη για την επιλογή των παραμέτρων του μοντέλου. Το BioBERT, όπως και άλλα μοντέλα βασισμένα στην αρχιτεκτονική Transformer, έχει ένα μέγιστο μήκος ακολουθίας εισόδου που μπορεί να επεξεργαστεί αποτελεσματικά (στην

περίπτωσή μας, ορίστηκε στα 384 tokens). Δεδομένου ότι οι περισσότερες περιλήψεις είναι σημαντικά μεγαλύτερες από αυτό το όριο σε αριθμό χαρακτήρων (και πιθανότατα και σε αριθμό tokens), καθίσταται σαφές ότι η περικοπή (truncation) των ακολουθιών εισόδου ήταν μια αναγκαία συνθήκη. Παρόλο που η περικοπή μπορεί να οδηγήσει σε απώλεια πληροφορίας από το τέλος των εκτενέστερων περιλήψεων, η πλειοψηφία της πληροφορίας που περιέχεται στα αρχικά τμήματα των περιλήψεων (που συνήθως είναι και τα πιο σημαντικά) διατηρείται. Η επιλογή του `max_seq_length = 384` αποτέλεσε έναν συμβιβασμό μεταξύ της κάλυψης ενός σημαντικού μέρους του κειμένου και της διατήρησης της υπολογιστικής εφικτότητας.

3. Τεχνικές Προκλήσεις και Περιορισμοί (στο notebook biosaqtrimpoueleftheria.ipynb)

Η ανάπτυξη ενός αποτελεσματικού συστήματος πολυετικετικής ταξινόμησης, ακόμη και μετά τη δημιουργία του οργανωμένου dataset `Preprocessed_BioASQ_2016b_TrainValTest`, προσέκρουσε σε σημαντικές τεχνικές προκλήσεις και περιορισμούς κατά την υλοποίηση των διαδικασιών μοντελοποίησης και εκπαίδευσης στο κύριο notebook της εργασίας (biosaqtrimpoueleftheria.ipynb).

1. Κατάρα της Διαστατικότητας (Curse of Dimensionality) και Αραιότητα Ετικετών:
 - Εξαιρετικά Υψηλή Διάσταση Εξόδου: Οι 23.495 μοναδικές ετικέτες MeSH δημιουργούσαν μια τεράστια κεφαλή ταξινόμησης (περίπου 18 εκατομμύρια παραμέτρους μόνο σε αυτή για το BioBERT με `hidden_size=768`), οδηγώντας σε απαγορευτικές απαιτήσεις μνήμης και υπολογιστικού κόστους.
 - Αραιότητα Δεδομένων (Data Sparsity): Πολλές ετικέτες είχαν ελάχιστες εμφανίσεις, καθιστώντας δύσκολη την εκμάθηση των προτύπων τους και επηρεάζοντας αρνητικά μετρικές όπως η F1-Macro.
 - Αρχικές Αποτυχημένες Προσπάθειες: Οι αρχικές, διερευνητικές προσπάθειες εκπαίδευσης με το πλήρες σύνολο ετικετών οδηγούσαν σταθερά σε σφάλματα CUDA out of memory κατά τη διάρκεια του backward pass, ακόμη και με batch size 1 ή 2. Η μείωση του batch size σε ακραία χαμηλές τιμές δεν έλυνε το πρόβλημα της μνήμης λόγω του μεγέθους της κεφαλής ταξινόμησης και καθιστούσε την εκπαίδευση μη πρακτική χρονικά. Ο χρόνος επεξεργασίας ακόμη και ενός μικρού ποσοστού των batches ήταν απαγορευτικός, καθιστώντας σαφές ότι μια προσέγγιση απευθείας προσέγγιση ήταν ανέφικτη.
2. Περιορισμοί Υπολογιστικών Πόρων Πλατφόρμας Kaggle:
 - Χρονικό Όριο Εκτέλεσης (Runtime Limit)
 - Περιορισμοί Μνήμης GPU (16GB) και RAM

- Αυτοί οι περιορισμοί επέβαλαν την αναζήτηση στρατηγικών βελτιστοποίησης πόρων.
- 3. Χαμηλή Απόδοση Αρχικού (Baseline) Μοντέλου:
Λόγω των παραπάνω προβλημάτων, δεν ήταν εφικτή η πλήρης εκπαίδευση ενός baseline μοντέλου με τις 23.495 ετικέτες. Οι ενδεικτικές τιμές από περιορισμένες δοκιμές ήταν: F1-Micro: 0.2319, F1-Macro: 0.1547, τιμές μη αποδεκτές.

Πίνακας 1: Αρχική (Εκτιμώμενη/Προβλεπόμενη) Απόδοση Μοντέλου (Πριν το Top-K Filtering)

Μετρική	Τιμή
F1-Micro	0.2319
F1-Macro	0.1547

4. Μεθοδολογία και Υλοποίηση

Για την αντιμετώπιση των προκλήσεων, αναπτύχθηκε η ακόλουθη μεθοδολογία.

4.1 Επισκόπηση Ροής Εργασιών και Βασικές Βιβλιοθήκες

Η ροή εργασιών περιλάμβανε: Ρύθμιση περιβάλλοντος, διαχείριση ρυθμίσεων, EDA, Top-K filtering, προετοιμασία δεδομένων, ορισμό μοντέλου, εκπαίδευση, αξιολόγηση και ανάλυση. Κύριες βιβλιοθήκες: Loguru, Torch, Transformers, Pandas, NumPy, Scikit-learn, Matplotlib, Seaborn, Tqdm, Joblib.

4.2 Ρύθμιση Περιβάλλοντος και Διαχείριση Ρυθμίσεων

- Ανίχνευση Hardware (Cell 2): Επιλογή συσκευής (CUDA/MPS/CPU).
- Δημιουργία Φακέλων Εξόδου (Cell 3a): Οργάνωση εξόδων.
- Κλάση Ρυθμίσεων BioASQConfig (Cell 3b): dataclass για κεντρική διαχείριση παραμέτρων (π.χ., `model_name="dmis-lab/biobert-v1.1"`, `max_seq_length=384`, `batch_size=14`, `learning_rate=3e-5`, `num_train_epochs=3`).

4.3 Στρατηγική Top-K Filtering Ετικετών (Cell 4b)

1. Σάρωση Συνόλου Εκπαίδευσης και Καταμέτρηση Συχνότητας: Στο `train_140k.jsonl` με `collections.Counter`.
2. Ανάλυση και Φιλτράρισμα Ετικετών – Επιλογή του "K":

- Από τις αρχικές 23.495 μοναδικές ετικέτες, επιλέχθηκαν TOP_K_LABELS = 2000. Η επιλογή του K=2000 ήταν ένας εμπειρικός συμβιβασμός: μια ανάλυση της κατανομής συχνότητας έδειξε ότι οι πρώτες ~2000 ετικέτες κάλυπταν ένα σημαντικό ποσοστό των συνολικών εμφανίσεων ετικετών, ενώ οι επόμενες είχαν δραματικά χαμηλότερες συχνότητες. Το K=2000 θεωρήθηκε ότι διατηρεί τις πιο πληροφοριακές ετικέτες, μειώνοντας την πολυπλοκότητα σε διαχειρίσιμο επίπεδο. Η παράμετρος MIN_LABEL_FREQUENCY = 5 δεν επηρέασε την τελική επιλογή των 2.000, καθώς όλες είχαν υψηλότερη συχνότητα, αλλά χρησίμευσε ως δικλείδα ασφαλείας.
 - Μείωση χώρου ετικετών κατά 91.5%.
3. Δημιουργία Mappings (label_to_id_map, id_to_label_map) και SELECTED_LABELS_SET.
 4. Ενημέρωση config.num_labels: Σε 2.000.

Πίνακας 2: Μείωση Διαστατικότητας Ετικετών με Top-K Filtering (Από Cell 4b)

Mapping με Top-K Filtering -  ΟΛΟΚΛΗΡΩΘΗΚΕ!
 2025-06-01 07:50:48.452 | INFO | __main__:<cell line: 0>:152 -  ΑΠΟΤΕΛΕΣΜΑ: 23,495 → 2,000 labels (91.5% μείωση)

4.4 Προετοιμασία Δεδομένων


- Φόρτωση Tokenizer (Cell 5a):
AutoTokenizer.from_pretrained(config.model_name).
- Κλάση MeSHDataset (Cell 5b): Η κλάση Dataset σχεδιάστηκε ώστε να διαβάζει κάθε άρθρο από το αρχείο JSONL μόνο όταν αυτό χρειάζεται, αντί να φορτώνει ολόκληρο το dataset στη μνήμη, χρησιμοποιώντας μηχανισμούς της βιβλιοθήκης linecache για αποδοτική πρόσβαση σε συγκεκριμένες γραμμές αρχείου. Υλοποιεί συνδυασμό τίτλου-περίληψης, tokenization και δημιουργία label vectors μόνο για τις 2.000 επιλεγμένες ετικέτες.
- Δημιουργία DataLoaders (Cell 5c): Για train, val, test sets με batch_size=config.batch_size (14).

4.5 Αρχιτεκτονική Μοντέλου (MeSHClassifier στο Cell 6a)

- Βασικό Μοντέλο: AutoModel.from_pretrained(config.model_name) (BioBERT).
- Κεφαλή Ταξινόμησης: nn.Dropout(config.classifier_dropout_rate) και nn.Linear(self.hidden_size, config.num_labels).

4.6 Διαδικασία Εκπαίδευσης

- Optimizer, Loss Function, Scheduler (Cell 6b):
 - Optimizer: optim.AdamW. Ο AdamW optimizer ρυθμίστηκε με διαφορετικό χειρισμό του weight_decay (0.01) για τις παραμέτρους βάρους (που υπόκεινται σε weight decay) και τις παραμέτρους bias/LayerNorm, όπως είναι σύνηθες για μοντέλα Transformer. Το learning rate ορίστηκε σε $3e-5$.
 - Loss Function: nn.BCEWithLogitsLoss().
 - Scheduler: get_linear_schedule_with_warmup με warmup_steps_ratio = 0.1. Η εκπαίδευση έγινε για num_train_epochs = 3, ένας αριθμός που αποτέλεσε συμβιβασμό μεταξύ επαρκούς εκπαίδευσης και διαθέσιμου χρόνου.
- Βρόχος Εκπαίδευσης (Cell 7):
 - AMP: torch.amp.GradScaler("cuda"). Το GradScaler χρησιμοποιείται στο πλαίσιο της AMP για να κλιμακώνει τις απώλειες πριν τον υπολογισμό των βαθμίδων (για την αποφυγή υποεκχείλισης των βαθμίδων μισής ακρίβειας) και στη συνέχεια επαναφέρει τις βαθμίδες στην αρχική τους κλίμακα πριν την ενημέρωση των βαρών.
 - Gradient Accumulation: config.gradient_accumulation_steps = 2.
 - Early Stopping: patience=2, threshold=0.001.
 - Αποθήκευση/Φόρτωση Μοντέλου: Το καλύτερο μοντέλο (βάσει val loss) αποθηκεύεται ως MODEL.state_dict() και φορτώνεται με MODEL.load_state_dict() για την τελική αξιολόγηση.
 - Αποτέλεσμα: Σχήμα 4.
 - Πάνω Γράφημα (Training & Validation Loss): Η εκπαιδευτική απώλεια (μπλε) και η απώλεια επικύρωσης (πορτοκαλί/κόκκινη) μειώνονται, με την καλύτερη εποχή να είναι η 3η.
 - Κάτω Γράφημα (Training Duration per Epoch): Σταθερός χρόνος ανά εποχή (~90 λεπτά).



Σχήμα 4: (Πάνω) Εξέλιξη της απώλειας εκπαίδευσης και επικύρωσης ανά εποχή. Η καλύτερη εποχή (3) επισημαίνεται. (Κάτω) Διάρκεια εκπαίδευσης ανά εποχή σε λεπτά. (Αποτέλεσμα εκτέλεσης του Cell 7).

4.6.1 Οπτικοποίηση της Πορείας Εκπαίδευσης (Σχήμα 4)

Το Σχήμα 4, το οποίο παράγεται στο τέλος του βρόχου εκπαίδευσης (Cell 7), παρέχει μια κρίσιμη οπτική επισκόπηση της διαδικασίας εκμάθησης του μοντέλου κατά τη διάρκεια των τριών εποχών. Αποτελείται από δύο επιμέρους γραφήματα:

1. Πάνω Γράφημα (Training & Validation Loss): Αυτό το γράφημα απεικονίζει την εξέλιξη της συνάρτησης απώλειας (BCEWithLogitsLoss) τόσο για το σύνολο εκπαίδευσης (μπλε καμπύλη με σημεία κύκλου) όσο και για το σύνολο επικύρωσης (πορτοκαλί/κόκκινη καμπύλη με σημεία τετραγώνου).
 - Παρατηρήσεις:
 - Η Training Loss ξεκινά από μια σχετικά υψηλή τιμή (περίπου 0.074) στην πρώτη εποχή και παρουσιάζει μια απότομη πτώση στη δεύτερη εποχή (περίπου 0.021), συνεχίζοντας να μειώνεται ελαφρώς στην τρίτη εποχή (περίπου 0.019). Αυτό υποδηλώνει ότι το μοντέλο μαθαίνει αποτελεσματικά από τα δεδομένα εκπαίδευσης.

- Η Validation Loss ξεκινά από μια χαμηλότερη τιμή (περίπου 0.024) στην πρώτη εποχή, μειώνεται ελαφρώς στη δεύτερη εποχή (περίπου 0.020) και παραμένει σχεδόν σταθερή ή μειώνεται οριακά στην τρίτη εποχή (περίπου 0.019-0.020).
 - Οι δύο καμπύλες συγκλίνουν προς το τέλος της εκπαίδευσης, και η καμπύλη επικύρωσης δεν παρουσιάζει αύξηση, πράγμα που υποδηλώνει ότι δεν υπάρχει εμφανές φαινόμενο υπερπροσαρμογής (overfitting) εντός των τριών εποχών εκπαίδευσης.
 - Η πράσινη διακεκομμένη γραμμή επισημαίνει την "Best Epoch (3)", υποδεικνύοντας ότι η τρίτη εποχή απέδωσε τη χαμηλότερη (ή μία από τις χαμηλότερες) τιμές απώλειας στο σύνολο επικύρωσης, και επομένως το μοντέλο που αποθηκεύτηκε από αυτή την εποχή είναι πιθανότατα το καλύτερο για γενίκευση.
2. Κάτω Γράφημα (Training Duration per Epoch): Αυτό το γράφημα δείχνει τη διάρκεια που απαιτήθηκε για την ολοκλήρωση κάθε εποχής εκπαίδευσης, συμπεριλαμβανομένης και της φάσης επικύρωσης στο τέλος κάθε εποχής.

Συνολικά, το Σχήμα 4 επιβεβαιώνει ότι η διαδικασία εκπαίδευσης ήταν σταθερή, το μοντέλο μάθαινε αποτελεσματικά χωρίς να υπερπροσαρμόζεται σημαντικά, και ο χρόνος εκπαίδευσης ήταν διαχειρίσιμος. Αυτά τα ευρήματα είναι ενθαρρυντικά και υποστηρίζουν την εγκυρότητα των αποτελεσμάτων που προέκυψαν από το εκπαιδευμένο μοντέλο.

4.7 Διαδικασία Αξιολόγησης (Memory-Safe) (Cell 8)

Φόρτωση καλύτερου μοντέλου και αξιολόγηση στο test set με chunk-based στρατηγική:

1. Μικρό test_batch_size = 6.
2. Chunks των chunk_size = 50 batches αποθηκεύονται προσωρινά (np.savez_compressed).
3. Επανασύνθεση TEST_PREDICTIONS_PROBS, TEST_TRUE_LABELS.
4. Σχήμα 5: Έξοδος κειμένου από αυτό το κελί, πριν την τελική βελτιστοποίηση κατωφλίου. Δείχνει Test F1-Micro 0.3456 (με κατώφλι 0.5) και Test Loss 0.0197.

```

=====
🚩 ENHANCED MEMORY-SAFE TEST EVALUATION COMPLETE!
=====
📊 Test Dataset: 30,000 samples
🔑 MeSH Labels: 2,000 terms
📊 Test F1-Micro: 0.3456
💾 Test Loss: 0.0197
=====
✅ Variables created for Advanced Analysis:
- TEST_PREDICTIONS_PROBS
- TEST_PREDICTIONS_BINARY
- TEST_TRUE_LABELS
💡 Memory optimized - ZERO RESTART RISK!
=====

```


Σχήμα 5: Έξοδος κειμένου από την ολοκλήρωση της αξιολόγησης στο σύνολο δοκιμής (Cell 8), πριν την εφαρμογή του βελτιστοποιημένου κατωφλίου. Το F1-Micro (0.3456) υπολογίζεται με το προκαθορισμένο κατώφλι 0.5.

5. Πειραματικά Αποτελέσματα και Ανάλυση

5.1 Βελτιστοποίηση Κατωφλίου Απόφασης (Cell 9)

Δοκιμάστηκαν κατώφλια από 0.1 έως 0.8 (βήμα 0.1) στις προβλέψεις του test set.

- Βέλτιστο κατώφλι: 0.20.
- Σχήμα 6, πάνω αριστερό γράφημα (Threshold Optimization): Η F1-Micro (μπλε) κορυφώνεται στο 0.20. Η F1-Macro (μωβ) παραμένει πολύ χαμηλή.



Σχήμα 6: Οπτικοποιήσεις από την προχωρημένη ανάλυση αποτελεσμάτων (Cell 9). (Πάνω Αριστερά) Βελτιστοποίηση Κατωφλίου. Η F1-Micro μεγιστοποιείται στο κατώφλι 0.20. (Πάνω Δεξιά) Το πλαίσιο "Precision-Recall Info" είναι ενδεικτικό, καθώς μια πλήρης ανάλυση Precision-Recall (π.χ., micro-averaged ή ανά ετικέτα) θα ήταν υπολογιστικά απαιτητική, απαιτώντας την επεξεργασία όλων των πιθανοτήτων για πολλαπλά κατώφλια και την αποθήκευση των αντίστοιχων τιμών precision/recall για κάθε σημείο της καμπύλης. (Κάτω Αριστερά) Απόδοση F1-Score για τις 10 ετικέτες με την καλύτερη απόδοση από ένα δείγμα 15 που αναλύθηκαν για λόγους αποδοτικότητας (βλ. ενότητα 5.4). (Κάτω Δεξιά) Σύγκριση τελικών μετρικών με το βέλτιστο κατώφλι 0.20. Η μπάρα F1-Macro είναι σχεδόν μηδενική (0.008) και δεν διακρίνεται εύκολα λόγω της κλίμακας, γεγονός που υπογραμμίζει τον αντίκτυπο του Top-K filtering σε αυτή τη μετρική.

5.1.1 Οπτική Επισκόπηση Αποτελεσμάτων Προχωρημένης Ανάλυσης (Σχήμα 6)

Το Σχήμα 6 (προερχόμενο από την εκτέλεση του Cell 9) συγκεντρώνει και οπτικοποιεί τα βασικά ευρήματα από την προχωρημένη ανάλυση των προβλέψεων του μοντέλου στο σύνολο δοκιμής. Αποτελείται από τέσσερα διακριτά γραφήματα:

1. Πάνω Αριστερά (Threshold Optimization): Αυτό το γράφημα απεικονίζει τη διαδικασία βελτιστοποίησης του κατωφλίου απόφασης. Η μπλε καμπύλη αναπαριστά την τιμή της μετρικής F1-Micro για διαφορετικές τιμές κατωφλίου (από 0.1 έως 0.8). Παρατηρείται ότι η F1-Micro μεγιστοποιείται (φτάνοντας περίπου στο 0.39) όταν το κατώφλι λαμβάνει την τιμή 0.20, η οποία

επισημαίνεται με την πορτοκαλί διακεκομμένη γραμμή. Η μωβ καμπύλη, που αναπαριστά την F1-Macro, παραμένει σταθερά σε πολύ χαμηλά επίπεδα, ανεξαρτήτως κατωφλίου, αντανakλώντας τον αντίκτυπο του Top-K filtering στην απόδοση των σπανιότερων ετικετών.

2. Πάνω Δεξιά (Precision-Recall Info): Αυτό το πλαίσιο είναι ενδεικτικό και φέρει τη σημείωση "Precision-Recall Analysis (Simplified for Memory)". Δεν παρουσιάζει μια πλήρη καμπύλη Precision-Recall, η δημιουργία της οποίας (π.χ., micro-averaged ή ανά ετικέτα) θα ήταν υπολογιστικά απαιτητική στο πλαίσιο των περιορισμών μνήμης του notebook. Μια τέτοια ανάλυση θα απαιτούσε την επεξεργασία όλων των πιθανοτήτων για πολλαπλά κατώφλια και την αποθήκευση των αντίστοιχων τιμών precision/recall για την κατασκευή των καμπυλών, κάτι που υπερέβαινε τις δυνατότητες της παρούσας υλοποίησης.
3. Κάτω Αριστερά (Top 10 Labels by F1 Score): Αυτό το ραβδόγραμμα παρουσιάζει την απόδοση (σε F1-Score) για τις 10 ετικέτες με την καλύτερη επίδοση από ένα περιορισμένο δείγμα 15 ετικετών που αναλύθηκαν για λόγους αποδοτικότητας μνήμης (οι πρώτες 15 ετικέτες βάσει του εσωτερικού τους index στο mapping, όχι απαραίτητα οι πιο συχνές από τις 2.000 ή οι συνολικά καλύτερα προβλεπόμενες). Παρατηρείται σημαντική διακύμανση στην απόδοση, με ορισμένες ετικέτες (L0, L3) να επιτυγχάνουν πολύ υψηλές F1-scores, υποδηλώνοντας ότι το μοντέλο είναι εξαιρετικά ακριβές για αυτές τις συγκεκριμένες έννοιες. Άλλες ετικέτες, όπως η L11, έχουν χαμηλότερη αλλά ακόμα αξιοπρεπή απόδοση (0.617). Αυτό το γράφημα υπογραμμίζει ότι η απόδοση δεν είναι ομοιόμορφη σε όλες τις ετικέτες, ακόμη και εντός των φιλτραρισμένων Top-2000.
4. Κάτω Δεξιά (Final Metrics Comparison): Αυτό το ραβδόγραμμα συνοψίζει τις βασικές μετρικές απόδοσης του μοντέλου μετά την εφαρμογή του βέλτιστου κατωφλίου 0.20. Δείχνει την F1-Micro (0.392), την Precision (Micro) (0.577), και την Recall (Micro) (0.296). Η μπάρα για την F1-Macro είναι οριακά ορατή, επιβεβαιώνοντας την τιμή 0.008. Αυτή η οπτικοποίηση επιτρέπει μια άμεση σύγκριση της ισορροπίας μεταξύ precision και recall, καθώς και της συνολικής απόδοσης F1-Micro.

Συνολικά, το Σχήμα 6 παρέχει κρίσιμες πληροφορίες για την επιλογή του βέλτιστου κατωφλίου, μια ένδειξη της απόδοσης σε επίπεδο μεμονωμένων ετικετών, και μια σαφή εικόνα των τελικών μετρικών που χαρακτηρίζουν την απόδοση του συστήματος.

5.2 Συνολική Απόδοση με Βέλτιστο Κατώφλι (Cell 9 και Cell 10)

Πίνακας 3: Τελική Απόδοση Μοντέλου στο Σύνολο Δοκιμής (με Top-K Filtering και Βέλτιστο Κατώφλι 0.20)


```
=====
🚀 MEMORY-SAFE ADVANCED ANALYSIS COMPLETE!
=====

🎯 Best Threshold: 0.200
📊 F1-Micro: 0.3918
📊 F1-Macro: 0.0079
📊 Subset Accuracy: 0.0023
📊 Hamming Loss: 0.0044
=====

✅ Analysis complete - Results saved!
💡 Memory optimized - NO RESTART RISK!
=====

🏁 FINAL TEST RESULTS:
🏆 F1-Micro: 0.3918
🏆 F1-Macro: 0.0079
🎯 Best Threshold: 0.200
📊 Subset Accuracy: 0.0023
📊 Hamming Loss: 0.0044
```

- Ανάλυση Γραφημάτων: Όπως είδαμε στο Σχήμα 6 (Threshold Optimization), το βέλτιστο κατώφλι 0.20 οδήγησε στις τελικές μετρικές που απεικονίζονται στο Σχήμα 6 (κάτω δεξιά, Final Metrics Comparison) και επιβεβαιώνονται στο Σχήμα 7 (πάνω δεξιά, Test Performance Metrics). Αυτή η σαφής σύνδεση μεταξύ της βελτιστοποίησης κατωφλίου και των τελικών αναφερόμενων μετρικών είναι σημαντική.



Σχήμα 7: Συνολικές οπτικοποιήσεις από την εκτέλεση του Cell 10. (Πάνω Αριστερά) Εξέλιξη Απώλειας Εκπαίδευσης. (Πάνω Δεξιά) Μετρικές Απόδοσης στο Σύνολο Δοκιμής, που προκύπτουν μετά την εφαρμογή του βέλτιστου κατωφλίου 0.20. (Κάτω Αριστερά) Κατανομή Δεδομένων στα σύνολα εκπαίδευσης, επικύρωσης και δοκιμής. (Κάτω Δεξιά) Περίληψη Πειράματος με παραμέτρους και βέλτιστα αποτελέσματα.

5.3 Υπολογιστικά Οφέλη

Επιβεβαιώνονται οι μειώσεις σε χρόνο εκπαίδευσης (270.2 λεπτά), χρήση GPU (~60%) και χώρο ετικετών (91.5%).

5.4 Ανάλυση Απόδοσης ανά Ετικέτα (Per-Label Analysis) (Cell 9)

Όπως παρατηρήθηκε στην ανάλυση του Σχήματος 6 (υπο-γράφημα "Top 10 Labels by F1 Score", ενότητα 5.1.1), η απόδοση του μοντέλου παρουσιάζει σημαντική διακύμανση όταν εξετάζεται σε επίπεδο μεμονωμένων ετικετών, ακόμη και εντός του περιορισμένου δείγματος που αναλύθηκε. Ενώ ορισμένες ετικέτες επιτυγχάνουν πολύ υψηλές τιμές F1-score, υποδηλώνοντας ότι το μοντέλο τις αναγνωρίζει με μεγάλη ακρίβεια και πληρότητα, άλλες παρουσιάζουν χαμηλότερες επιδόσεις.

Αυτή η διαφοροποίηση στην απόδοση ανά ετικέτα μπορεί να αποδοθεί σε διάφορους παράγοντες:

1. Συχνότητα Εμφάνισης της Ετικέτας: Παρόλο που όλες οι 2.000 ετικέτες που επιλέχθηκαν είχαν μια ελάχιστη συχνότητα εμφάνισης, εξακολουθεί να υπάρχει σημαντική διακύμανση στη συχνότητά τους. Ετικέτες που είναι πιο συχνές (ακόμη και εντός των Top-2000) παρέχουν περισσότερα παραδείγματα

εκπαίδευσης στο μοντέλο, επιτρέποντάς του δυνητικά να μάθει καλύτερα τα χαρακτηριστικά τους.

2. Διακριτότητα των Σημάτων στο Κείμενο: Ορισμένες ιατρικές έννοιες μπορεί να εκφράζονται με πολύ συγκεκριμένη και επαναλαμβανόμενη ορολογία στους τίτλους και τις περιλήψεις, καθιστώντας την ανίχνευσή τους από το μοντέλο ευκολότερη. Αντίθετα, άλλες έννοιες μπορεί να περιγράφονται με πιο ποικιλόμορφη γλώσσα ή να απαιτούν βαθύτερη σημασιολογική κατανόηση για την αναγνώρισή τους.
3. Βαθμός Αλληλοεπικάλυψης με Άλλες Ετικέτες: Εάν μια ετικέτα συχνά συνυπάρχει ή συγχέεται σημασιολογικά με άλλες παρόμοιες ετικέτες, το μοντέλο μπορεί να δυσκολεύεται να τις διακρίνει με απόλυτη ακρίβεια.
4. Ποιότητα και Συνέπεια των Αρχικών Επισημειώσεων: Αν και οι επισημειώσεις MeSH θεωρούνται υψηλής ποιότητας, πάντα υπάρχει η πιθανότητα υποκειμενικότητας ή διαφοροποιήσεων στον τρόπο που οι ανθρωπίνι επιμελητές αναθέτουν τις ετικέτες, κάτι που μπορεί να επηρεάσει την εκμάθηση του μοντέλου.

Η παρατήρηση ότι η απόδοση ποικίλλει είναι σημαντική. Υπογραμμίζει ότι οι συνολικές μετρικές, όπως η F1-Micro, παρέχουν μια γενική εικόνα, αλλά δεν αποκαλύπτουν πλήρως τις επιμέρους επιτυχίες ή αδυναμίες του μοντέλου σε συγκεκριμένες κατηγορίες. Για μια πιο στοχευμένη βελτίωση του συστήματος, μια λεπτομερής ανάλυση σφαλμάτων και απόδοσης για ένα ευρύτερο φάσμα μεμονωμένων ετικετών (πέραν του μικρού δείγματος που εξετάστηκε εδώ λόγω υπολογιστικών περιορισμών) θα ήταν εξαιρετικά χρήσιμη, επιτρέποντας τον εντοπισμό των ετικετών που αποτελούν "αδύναμους κρίκους" και την πιθανή εφαρμογή εξειδικευμένων στρατηγικών για αυτές.

5.5 Άλλες Οπτικοποιήσεις (Cell 7, Cell 10)

Το Σχήμα 7 (προερχόμενο από την εκτέλεση του Cell 10) παρέχει μια ολοκληρωμένη και συνοπτική οπτικοποίηση των βασικών πτυχών και αποτελεσμάτων του πειράματος. Αποτελείται από τέσσερα επιμέρους γραφήματα:

1. Πάνω Αριστερά (Training Progress): Αυτό το γράφημα είναι παρόμοιο με το Σχήμα 4 (από το Cell 7) και απεικονίζει την εξέλιξη της συνάρτησης απώλειας τόσο για το σύνολο εκπαίδευσης (μπλε γραμμή) όσο και για το σύνολο επικύρωσης (μωβ/πορτοκαλί γραμμή) κατά τη διάρκεια των τριών εποχών εκπαίδευσης. Η σταθερή μείωση και των δύο καμπυλών, με την καμπύλη επικύρωσης να ακολουθεί στενά την καμπύλη εκπαίδευσης και να φτάνει στο ελάχιστό της στην 3η εποχή (όπως υποδεικνύεται από την πορτοκαλί διακεκομμένη γραμμή), επιβεβαιώνει την καλή σύγκλιση του μοντέλου και την απουσία σημαντικού overfitting εντός του συγκεκριμένου αριθμού εποχών.
2. Πάνω Δεξιά (Test Performance Metrics): Αυτό το ραβδόγραμμα συνοψίζει τις βασικές μετρικές απόδοσης του μοντέλου στο αθέατο σύνολο δοκιμής, μετά την εφαρμογή του βέλτιστου κατωφλίου (0.20). Παρατηρούμε την τιμή F1-Micro (0.392), την Precision (Micro) (0.577), την Recall (Micro) (0.296), την εξαιρετικά χαμηλή F1-Macro (0.008) και την επίσης χαμηλή Subset Accuracy (0.002). Αυτό

το γράφημα οπτικοποιεί τα βασικά αποτελέσματα που παρουσιάζονται και στον Πίνακα 3, επιτρέποντας μια γρήγορη σύγκριση των διαφορετικών μετρικών.

3. Κάτω Αριστερά (Dataset Distribution): Το κυκλικό διάγραμμα (pie chart) απεικονίζει την ποσοστιαία κατανομή των δειγμάτων στα τρία υποσύνολα δεδομένων που χρησιμοποιήθηκαν: Εκπαίδευση (Training: 140.000 δείγματα, 70.0%), Επικύρωση (Validation: 30.000 δείγματα, 15.0%) και Δοκιμή (Test: 30.000 δείγματα, 15.0%). Αυτό επιβεβαιώνει τον διαχωρισμό που έγινε κατά την προετοιμασία του dataset (ενότητα 2.1).
4. Κάτω Δεξιά (Experiment Summary): Αυτό το πλαίσιο κειμένου παρέχει μια συνοπτική επισκόπηση των βασικών παραμέτρων του πειράματος και των τελικών αποτελεσμάτων. Περιλαμβάνει πληροφορίες όπως το όνομα του μοντέλου (dmis-lab/biobert-v1.1), το μέγιστο μήκος ακολουθίας (384), το μέγεθος δέσμης (14), τον ρυθμό εκμάθησης ($3e-5$), τον συνολικό αριθμό παραμέτρων του μοντέλου (περίπου 135 εκατομμύρια), καθώς και τις κυριότερες τελικές μετρικές (F1-Micro: 0.3918, F1-Macro: 0.0079, Best Threshold: 0.200).

Συνολικά, το Σχήμα 7 λειτουργεί ως μια αποτελεσματική "ταυτότητα" του πειράματος, συγκεντρώνοντας τις πιο κρίσιμες πληροφορίες για την εκπαίδευση, την απόδοση, τα δεδομένα και τη διαμόρφωση του μοντέλου σε μία ενιαία οπτικοποίηση.

6. Συζήτηση και Ανάλυση Σφαλμάτων

6.1 Ερμηνεία Αποτελεσμάτων και Trade-offs

Η στρατηγική του Top-K filtering ήταν ένας αναγκαίος συμβιβασμός. Η F1-Micro (0.3918) είναι ικανοποιητική υπό τις συνθήκες. Η υψηλότερη Precision (0.577) έναντι της Recall (0.296) υποδηλώνει ότι το μοντέλο είναι πιο συντηρητικό. Η F1-Macro (0.0079) υποδηλώνει την αγνόηση των σπάνιων ετικετών.

6.3 Περιορισμοί της Μελέτης

Παρά την επίτευξη ενός λειτουργικού συστήματος και την εξαγωγή χρήσιμων συμπερασμάτων, η παρούσα μελέτη ενέχει ορισμένους περιορισμούς που είναι σημαντικό να αναγνωριστούν και οι οποίοι ενδέχεται να επηρέασαν τα τελικά αποτελέσματα ή να περιορίζουν τη γενικευσιμότητά τους:

1. Υπολογιστικοί Περιορισμοί και οι Συνέπειές τους: Όπως αναλύθηκε εκτενώς, οι αυστηροί περιορισμοί της πλατφόρμας Kaggle (χρόνος εκτέλεσης, μνήμη GPU/RAM) αποτέλεσαν τον κύριο καθοδηγητικό παράγοντα για πολλές σχεδιαστικές επιλογές. Αυτοί οι περιορισμοί:

- Επέβαλαν τη στρατηγική Top-K Filtering: Η αδυναμία διαχείρισης του πλήρους συνόλου των 23.495 ετικετών οδήγησε στην απόφαση εστίασης στις 2.000 πιο συχνές, αγνοώντας το 91.5% των σπανιότερων ετικετών. Αυτό είχε άμεσο αντίκτυπο σε μετρικές όπως η F1-Macro.
 - Περιορίσαν το βάθος της εκπαίδευσης: Ο αριθμός των εποχών (3) ήταν σχετικά μικρός, επιλεγμένος για να εξασφαλίσει την ολοκλήρωση εντός των χρονικών ορίων. Περισσότερες εποχές, με κατάλληλη διαχείριση του overfitting, θα μπορούσαν δυνητικά να οδηγήσουν σε καλύτερη σύγκλιση.
 - Περιορίσαν το μέγεθος της δέσμης (batch size): Αν και αντισταθμίστηκε μερικώς με gradient accumulation, μεγαλύτερα batch sizes (αν ήταν εφικτά) θα μπορούσαν να οδηγήσουν σε πιο σταθερές εκτιμήσεις των βαθμίδων.
2. Έλλειψη Εκτεταμένου Hyperparameter Tuning: Λόγω των χρονικών και υπολογιστικών περιορισμών, δεν πραγματοποιήθηκε μια συστηματική και εκτεταμένη διαδικασία βελτιστοποίησης των υπερπαραμέτρων του μοντέλου (π.χ., learning rate, batch size, αριθμός εποχών, αρχιτεκτονική της κεφαλής ταξινόμησης, παράμετροι dropout, ρυθμίσεις του optimizer). Οι επιλεγμένες τιμές βασίστηκαν κυρίως σε συνήθειες πρακτικές για μοντέλα τύπου BERT και σε περιορισμένες, εμπειρικές δοκιμές. Μια πιο διεξοδική αναζήτηση στον χώρο των υπερπαραμέτρων θα μπορούσε ενδεχομένως να οδηγήσει σε περαιτέρω βελτίωση της απόδοσης του μοντέλου.
3. Στατική και Απλοϊκή Επιλογή Ετικετών (Top-K Filtering): Η επιλογή των 2.000 ετικετών βασίστηκε αποκλειστικά στη συχνότητα εμφάνισής τους στο σύνολο εκπαίδευσης. Αυτή η προσέγγιση, αν και πρακτική, είναι στατική και δεν λαμβάνει υπόψη άλλους παράγοντες που θα μπορούσαν να οδηγήσουν σε μια πιο πληροφοριακή επιλογή υποσυνόλου ετικετών, όπως:
- Την ιεραρχική δομή των MeSH: Η απλή επιλογή βάσει συχνότητας μπορεί να παραλείψει σημαντικές, αν και λιγότερο συχνές, εξειδικευμένες ετικέτες ή να οδηγήσει σε μια μη ισορροπημένη κάλυψη των διαφόρων κλάδων της ιεραρχίας MeSH.
 - Τη σημασιολογική σπουδαιότητα ή την κλινική σημασία ορισμένων όρων που μπορεί να μην είναι οι πιο συχνοί.
 - Την αλληλεξάρτηση μεταξύ των ετικετών.
4. Βελτιστοποίηση Κατωφλίου Απόφασης στο Σύνολο Δοκιμής: Η διαδικασία βελτιστοποίησης του κατωφλίου απόφασης (threshold tuning), όπως περιγράφεται στην υλοποίηση (Cell 9), φαίνεται να χρησιμοποιεί τις προβλέψεις που παρήχθησαν από το σύνολο δοκιμής (TEST_PREDICTIONS_PROBS) για να βρει το κατώφλι που μεγιστοποιεί την F1-Micro. Μεθοδολογικά, η βελτιστοποίηση οποιασδήποτε παραμέτρου, συμπεριλαμβανομένου του κατωφλίου, θα έπρεπε ιδανικά να γίνεται αυστηρά στο σύνολο επικύρωσης (validation set). Η χρήση του συνόλου δοκιμής για αυτόν τον σκοπό μπορεί να οδηγήσει σε μια υπεραισιόδοξη εκτίμηση της απόδοσης, καθώς το κατώφλι

προσαρμόζεται στα συγκεκριμένα χαρακτηριστικά του test set (μικρή διαρροή πληροφορίας - data leakage). Αυτή η παραχώρηση έγινε στο πλαίσιο της συγκεκριμένης υλοποίησης, πιθανώς για λόγους απλότητας στη δομή του notebook ή λόγω της εστίασης στην επίτευξη ενός λειτουργικού συστήματος εντός των δεδομένων περιορισμών. Σε μια αυστηρά ερευνητική προσέγγιση, το validation set θα ήταν το κατάλληλο για αυτόν τον σκοπό.

5. Περιορισμένη Ανάλυση Σφαλμάτων: Δεν πραγματοποιήθηκε μια εκτενής ποιοτική ή ποσοτική ανάλυση των σφαλμάτων του μοντέλου (π.χ., εξέταση false positives/negatives, ανάλυση σύγχυσης μεταξύ ετικετών), κυρίως λόγω χρονικών περιορισμών. Μια τέτοια ανάλυση θα μπορούσε να προσφέρει βαθύτερη κατανόηση των αδυναμιών του μοντέλου και να καθοδηγήσει μελλοντικές βελτιώσεις.

Η αναγνώριση αυτών των περιορισμών είναι σημαντική για την ορθή ερμηνεία των αποτελεσμάτων και για τον σχεδιασμό μελλοντικών ερευνητικών προσπαθειών.

7. Συμπεράσματα

Η αντιμετώπιση του προβλήματος της πολυετικετικής ταξινόμησης ιατρικών άρθρων BioASQ 2016b, με τον εντυπωσιακό αριθμό των 23.495 πιθανών ετικετών MeSH και τους αυστηρούς υπολογιστικούς περιορισμούς της πλατφόρμας Kaggle, αποτέλεσε μια σημαντική πρόκληση. Οι αρχικές απόπειρες να διαχειριστούμε το πρόβλημα στην πλήρη του διάσταση κατέδειξαν γρήγορα την υπολογιστική του πολυπλοκότητα, οδηγώντας σε προβλήματα μνήμης και μη πρακτικούς χρόνους εκπαίδευσης. Παρά τις αρχικές αυτές δυσκολίες, η παρούσα εργασία κατάφερε να αναπτύξει και να αξιολογήσει με επιτυχία ένα λειτουργικό σύστημα ταξινόμησης, υιοθετώντας μια στρατηγική προσέγγιση.

Η κεντρική απόφαση για την εφαρμογή του Top-K Filtering, μειώνοντας τον χώρο των ετικετών στις 2.000 πιο συχνές, σε συνδυασμό με σχολαστικές τεχνικές βελτιστοποίησης της μνήμης, αποδείχθηκε καθοριστική. Αυτή η μεθοδολογία όχι μόνο κατέστησε το πρόβλημα υπολογιστικά εφικτό αλλά οδήγησε και στην επίτευξη μιας αξιολογής απόδοσης F1-Micro της τάξης του 0.3918. Το αποτέλεσμα αυτό υπογραμμίζει την ικανότητα του μοντέλου BioBERT, όταν εστιάζει σε ένα πιο διαχειρίσιμο υποσύνολο, να αναγνωρίζει με ικανοποιητική ακρίβεια τις πιο διαδεδομένες ιατρικές έννοιες.

Αναγνωρίζεται ότι η εστίαση αυτή είχε ως αναπόφευκτη συνέπεια τη χαμηλή απόδοση στη μετρική F1-Macro, καθώς οι σπανιότερες ετικέτες εξαιρέθηκαν. Ωστόσο, δεδομένου του πλαισίου και των περιορισμών, η επίτευξη ενός σταθερού, εκπαιδευσιμίου και αξιολογήσιμου μοντέλου που παρέχει χρήσιμες προβλέψεις για ένα σημαντικό υποσύνολο των ετικετών, συνιστά από μόνη της ένα σημαντικό βήμα προόδου. Η πρακτική αξία αυτής της προσέγγισης έγκειται στη δυνατότητα εφαρμογής της σε περιβάλλοντα με περιορισμένους πόρους, προσφέροντας μια ρεαλιστική λύση για την αυτόματη ευρετηρίαση μεγάλου όγκου ιατρικών κειμένων.

Συμπερασματικά, η εργασία αυτή καταδεικνύει ότι ακόμη και εξαιρετικά πολύπλοκα προβλήματα μπορούν να προσεγγιστούν αποτελεσματικά μέσω στρατηγικών

απλοποίησης και προσεκτικής διαχείρισης πόρων, οδηγώντας σε πρακτικά και χρήσιμα αποτελέσματα, υπερνικώντας τις αρχικές τεχνικές και υπολογιστικές προκλήσεις.